# 虚拟临床研究整改：先接通回路，再亮出假设

六类论文的流程其实是同一条线：先说清问题和用途，按手里的数据定路线和能说到哪一步，模型把话变成带出处的规格，代码和引擎算数字，诊断和敏感性随结果一起出，结果分级给出，改一句就出新版本。**我们的模块应该按这一条线组织，四个任务是这条线的四种走法，全部发生在同一段原生对话里，用户不需要走任何步骤。** 我们的引擎和诚实标签已经比多数论文系统严，差距在两头：前面缺召回、路线记录和预演，后面是结果到不了用户、诊断算了却不显示。所以整改分四期：Phase 0 接通“对话→首页→结果页→回到对话”的回路；Phase 1 把悄悄生效的假设亮出来（没有零效应情景、脱落率默认 0、相关性默认独立）；Phase 2 减少模型弯路、补匹配的短板；Phase 3 按需求加深能力。全部 44 项，其中 Phase 0 和 Phase 1 的 21 项大多不到一天。这份方案不新增任何审批、硬关卡或表单。有一个风险要先知道：简报建议的“把对话研究并入首页列表”，如果直接放宽现有查询，会把 PR #17 修掉的那类缺陷带回来（通用项目被研究占用），必须换一种做法（见第 4.3 节）。

## 1. 结论：回路断在结果之后，不断在计算之前

| 你想问的 | 答案 |
|---|---|
| 论文的流程是什么 | 六类论文共用八步：问题与用途 → 路线与声明上限 → 带出处的规格 → 亮出规格和默认值 → 确定性计算 → 自动诊断与敏感性 → 结果分级 → 留档可改。它们的分歧主要在人站在哪、未知怎么算、谁来汇总（第 2 节）。 |
| 模块该怎么组织 | 一条线，四种走法。八步是 AI 在一轮对话里做的事，不是页面步骤。用户只碰四样东西：一句话、一条带假设和类别的回复、首页列表、结果页（第 3 节）。 |
| 我们差在哪 | 引擎强，两头弱。很多能力已经做了但默认不跑或不显示（E 值、阴性对照、敏感性网格、借用设计的假阳性表）；文献当作方法的规则，在我们这里只是技能里的一句话（零效应情景、目标试验、适用性判断）（第 4 节）。 |
| 先做什么 | 接通回路（6 项），再亮出假设（15 项）。其中单项收益最大的三件：回复能跳到结果页；首页列出对话里的研究；所有设计默认跑零效应情景（第 5 节）。 |
| 不做什么 | 招募和运营、审批关卡、参数表单、强制步骤、成败预测分、让大模型生成患者数据、用合成患者补对照组、大规模评测（第 6 节）。 |

**和未合入分支的关系。** `codex/module-workspace-20261101`（领先 46 个提交，基于 `5c740327b`，未合入、未部署）做的是跨模块工作台，没有修这个断点：我在该分支上复核，`listStudies` 仍只取 `scope='project'`，`useGeneralResearchDraft` 仍进通用对话，`createVcrStudy` 仍没有界面调用者，首页空状态写着“在对话里说明要研究什么，发送后研究会列在这里。”，这句话依然不成立。我也比对了文件：服务端主干（`vcrStore`、`vcrOrchestrator`、`vcrGateway`、`vcrViewsTabs`、`vcrJobs`）、`vcr_platform.py`、全部技能和 R 引擎，这条分支都没碰。**所以后端、引擎和技能的改动现在就能开工；碰 `VcrHomePage`、各结果页签、`vcrService`、`vcrViews` 的改动要等它合入，否则必冲突。** 下文用“合并后”标出。

**本方案能证明和不能证明的。** 代码事实读自 `github/main` 77ba0a436，我抽查了其中最要紧的十余条，都成立；没有运行任何测试、引擎或浏览器，也没有读生产开关，所以界面相关的话都是“代码会这样画”。

## 2. 论文里的实际流程：分歧在人和未知，不在骨架

### 2.1 患者—试验匹配：逐条读，代码汇总，人看短名单

| 系统 | 先缩小范围 | 入排条件怎么用 | 从病历取证据 | 每条的标签 | 谁汇总 | 人在哪 |
|---|---|---|---|---|---|---|
| TrialGPT | 模型写关键词，词法加语义检索，留前 500 | 原文直接给模型 | 病历句子编号 | 符合/不符合/信息不足/不适用 | 代码打分加模型打分 | 专家留在回路 |
| TrialGPT 2.0 | 超过 1,500 个试验才检索 | 不逐条 | 不逐条列出 | 无；符合理由/缺失/不符合理由 | **模型给 0–100 分**，代码按阈值分档 | 医生决定 |
| PRISM | 按癌种 | 每个试验解析一次成是非题 | 按时间排序的片段 | 是/否/N/A | **代码**按布尔逻辑，未知按概率处理 | 只用于评估 |
| UTSW 部署 | 按团队的试验表 | 人挑 2–7 条分两层 | 每条取 30 个片段 | 六种（含不确定、无文档） | **代码**算百分比 | 协调员审每个候选 |
| TrialMatchAI | 年龄、性别、地点、状态预筛，再混合检索 | 每条单独建索引 | 检索上下文 | 符合/不符合/不清/无关 | **代码**，不清和无关不计分 | 未说明 |
| Massive Bio（厂商） | 每月解析登记库 | 进知识图谱 | 模型代理 | 配对级三类 | 图谱规则加模型 | 约 15% 优先人审 |
| RECTIFIER 随机试验 | 结构化查询先筛 | 固定问题集 | 读病历和报告 | 页面未写 | 页面未写 | 页面未写 |

论文一致的有四点：模型读之前先用便宜办法缩小范围；长病历从不整份给模型，而是按条件取片段或先做摘要；每个判断带理由和证据指向；人看的是短名单。

分歧有三处，都影响我们。第一，**未知怎么算没有共识**：有的并入“不符合”（Wornow），有的单列后不计分（TrialMatchAI），有的按概率处理（PRISM），有的只降低信心（TrialGPT 2.0）。第二，**谁汇总**：多数用代码，只有 TrialGPT 2.0 让模型直接打总分。逐条读加代码汇总这一类是唯一留下逐条审计线索、也能把“未知”和“不符合”分开的做法，我们已经站在这一类。第三，**预测的东西不一样**：TrialGPT 2.0 的前瞻运行里，339 个候选有 83.2% 被医生标为“符合但不推荐”，只有 13.3% 被推荐。这说明“符合”不等于“值得看”，匹配结果不能被读成推荐。

准确率不能跨论文比。合成或理想化病历上逐条约 87–91%（TrialGPT 87.3%，Ferber 88.0%）；真实病历上 PRISM 的 GPT-4 是 68%，同一批题里专家只有 70%，五人一致率 64%。UTSW 的 0.94 算的是剔除“不确定”后、已被排到前面的患者。人和人本身就不太一致，n2c2 2018 的两位标注者 Cohen's kappa（扣除碰巧一致后的一致程度）平均只有 0.54。唯一的随机试验 RECTIFIER 显示，好处主要是快：完成筛查的人里合格率相同（20.8% 对 21.1%），但试验结束时未筛的是 37 人对 887 人。

### 2.2 虚拟人群与虚拟患者：数据等级决定能说到哪

| 路线 | 要什么 | 怎么生成 | 怎么检验 | 已有结果 | 能说到哪 |
|---|---|---|---|---|---|
| 机制模型虚拟人群（Allen） | 微分方程模型、参数范围、目标分布 | 过量生成“合理患者”，再抽样匹配目标 | 比对目标分布，FDA 称这是校准 | 都是厂商口径：复现 AFFIRM 高估疗效（>90% 对 67%）；FLAURA2 前瞻预测 HR 0.602 对实测 0.62 | 带假设的投影 |
| 从个体数据合成（Azizi、El Emam） | 整份试验个体数据 | 序贯决策树、对抗网络 | 分布距离、重跑分析、隐私风险 | 风险比置信区间重叠 61%–86% | 方法开发和数据共享 |
| 合成患者补对照组（Fernandes，预印本，只读摘要） | 部分真实对照 | CTGAN/TVAE | 对比原随机试验 | 风险差相对偏差 76%–133% | **不能用** |
| 从发表汇总生成（Guyot、SASC） | KM 曲线（生存曲线）、风险人数、事件数、基线表 | 反推个体、按分布抽样 | 对照原文统计量 | 生存概率误差约 0.3%；对数风险比误差从 0.017 升到 0.198（两项信息都缺时） | 设计和教学，相关结构只能算假设 |
| 预后校正（Schuler、EMA 意见） | 随机试验、独立训练的预后模型 | 模型预测作为协变量 | 模型差也不破坏 I 类错误（没效果却判有效的概率） | AWARE 摘要样本量省 5%–10% | 只提高随机试验效率 |
| 个体预测（DT-GPT、TwinWeaver、Delphi-2M） | 大量真实病历 | 微调模型 | 留出患者、外部登记 | DT-GPT 比最强基线只好 1.3%–3.4%，罕见危急事件 AUC（区分能力，0.5 等于瞎猜）0.506 | 研究级预测，作者不认可因果解读 |
| 大模型扮演患者（Bisbee，政治调查，转到临床是推断） | 提示词 | 角色扮演 | 对照真实调查 | 方差被压缩，48% 回归系数显著不同，其中 32% 反号 | 无 |

能过监管和报告规范的路线共用七步：决策与用途及风险；来源及相关性清单；生成；校准；用独立数据验证；适用性与不确定性；计划与报告。关键区分来自 FDA 器械模拟指南：**校准不是验证**，把模型调到贴合目标分布，证据很弱；ICH M15 要求识别假设、讨论替代方案、做稳健性分析。模型换人群必然打折：Delphi-2M 外部 AUC 从 0.69 掉到 0.67，Epic 脓毒症模型 从开发方的 0.76–0.83 掉到 0.63。STRATOS 说外部应用至少要看校准截距和斜率。要说明的是，这些路线我们只走统计这一支，机制模型是 Nova jinkō 的路。

### 2.3 外部对照与目标试验模拟：先问能不能比，再算

| 步骤 | 目标试验模拟（Hernán、TARGET） | 单臂加外部对照（FDA 2023 草案、因果综述） | 混合对照（CDE 2026 第 6 号、RBesT） | MAIC（NICE TSD 18） | 预后校正（FDA 2023） |
|---|---|---|---|---|---|
| 先定什么 | 七要素方案：入选、策略、分配、随访、结局、对比、分析 | 适用性判断 | 外部来源可比性 | 有无共同对照（锚定/非锚定） | 随机 |
| 数据门槛 | 两策略都观察到，基线混杂都在 | 两组个体数据 | 院内随机对照加外部数据 | 一方个体数据，一方汇总 | 随机试验加独立历史数据 |
| 时间零点 | 符合条件且开始策略的时刻 | 共同索引日期 | 从随机开始 | 不适用 | 随机 |

| 步骤 | 目标试验模拟（Hernán、TARGET） | 单臂加外部对照（FDA 2023 草案、因果综述） | 混合对照（CDE 2026 第 6 号、RBesT） | MAIC（NICE TSD 18） | 预后校正（FDA 2023） |
|---|---|---|---|---|---|
| 平衡或借用 | 倾向评分匹配或加权 | 加权、结局模型、AIPW（双重稳健） | 带预设权重的先验 | 矩匹配权重 | 线性模型加协变量 |
| 诊断 | 前后平衡、流向计数、对照结局 | 对预设阈值看平衡和重叠 | 先验有效样本量、冲突检查 | 有效样本量、权重分布 | 稳健标准误 |
| 敏感性 | 阴性对照、定量偏倚分析 | 临界点、E 值、比例风险检查 | 假阳性仿真（例如至少 10 万次）、不借用对比 | 锚定要有效应修饰证据，非锚定要残余误差估计 | 样本量按未校正算偏保守 |

表里的术语：倾向评分是估计每人进某组的概率，用来配平两组；MAIC 是用权重把一方的个体数据调成另一方已发表的基线再比；风险比（HR）是治疗组相对对照组的事件风险；E 值是未测混杂要多强才能解释掉结果；临界点是偏倚要多大结论才翻。

共同逻辑是**统计之前先判断能不能比**。FDA 说很多情况下外部对照难以可信，该换设计，不建议非劣效，预期效应不大时也可能不合适；EMA 要求保守阈值；CDE 第 54 号列四个条件，第 27 号 说多数情况不建议历史对照。这里 FDA 文件仍是草案，因果综述是有 FDA 作者参与的预印本。

选路线靠四道判断：有没有随机；比较的每一方有没有个体数据；自然史是否稳定、效应是否大；能否锚定在试验人群上。非锚定 MAIC 被 TSD 18 明说假设“被普遍认为不可行”，只在没有连通证据时才考虑，而且要给残余误差范围。

可信度的硬数字有三个。RCT-DUPLICATE 用理赔数据模拟 32 个试验，相关系数在紧密模拟的 16 个是 0.93，其余 16 个是 0.53，这个分组是事后划的。Bartlett 估计高影响期刊的试验只有约 15% 能用真实世界数据复现（我只读到二手摘要）。Gupta 在肺癌里测到外部对照与原对照的风险比之比，从未校正 1.36 降到校正后 1.22，加定量偏倚分析后 1.17，也就是校正后仍差约 17%（我读的是记录页摘要，原文未开）。Friends of Cancer Research 海报 里九家用同一分析计划，风险比从约 0.9 到 1.4。

阈值没有定论：SMD（标准化均数差，两组某指标差多少）0.1 只是惯例，Austin 说固定切点武断，FDA 不背书单一方法。阴性对照结果为零也不证明没有偏倚（Lipsitch）。BenchExCal 校准法目前只有设计论文，没有性能结果。

### 2.4 试验设计仿真：公式先行，零效应情景和基准设计不可省

| 阶段 | 论文和指南要什么 | 平台能自动做吗 |
|---|---|---|
| 决策问题 | 目标直接对应要做的决定（ICH E20 草案、ADEMP） | 要人说，AI 可起草 |
| 候选设计 | 必须含基准设计（E20） | 能，自动并列 |
| 假设 | 效应分“重要”和“现实”（DELTA2），对照率、脱落、入组要有来源和范围 | AI 先查文献 |
| 运行特征（设计在各种真实情况下的表现） | I 类错误、把握度（真有效时判出有效的概率）、期望样本量、时长、偏倚、覆盖率、蒙特卡洛误差（仿真本身的抖动） | 能 |
| 敏感性 | 对输入的敏感性（DELTA2、E20）；检验规则不重新校准（Granholm） | 能 |

| 阶段 | 论文和指南要什么 | 平台能自动做吗 |
|---|---|---|
| 建议 | 权衡表和临床讨论；最终选择归申办方（FDA 2019） | 可写初稿 |
| 报告 | E20 的 11 项，含示例单次试验、种子和代码 | 大部分能组装 |

默认用公式，公式算不了才用仿真，这是 FDA 2019 的立场。非比例风险（效应随时间变）的分组序贯设计（中途可提前结束的设计），公式与 100 万次仿真只差约 0.005（Zhao），所以仿真在这里是复核。重复次数的惯例是：报告 I 类错误时每情景 10 万次（FDA 2019、E20、CDE 第 6 号的例子、Granholm），把握度等 1 万次够。方法学本身只要求从目标精度倒推，并报告误差，Morris 回顾的 100 篇论文里 93 篇没报。

假设最常错的是效应。危重症试验 预期绝对差 10.1%，实测 1.4%；肿瘤三期 预期 HR 0.66，实测 0.72（我只读到简报摘要）。我们按公式自己算的例子（不是发表数字）：按 HR 0.66 定 90% 把握度，真实 0.72 时只剩约 73%，上线前要用 rpact 核一遍。Charles 审计 215 个试验：43% 缺必需参数，可复算的有 30% 差异超过 10%。脱落反而不太离谱，Walters 的中位留存 89%，但只有 56% 按目标招满。

效应形状也重要。Zhao 的例子里延迟或交叉效应让普通 log-rank 把握度从 0.875 掉到 0.724、0.691，MaxCombo（组合多种加权的检验）保持 0.825、0.859。但 Klinglmüller 的 10,608 个情景比较发现，全量研究中普通 log-rank 在多数情景仍属最强之列，所以没有一个默认检验是绝对安全的，应该把形状作为情景，不要换默认。成败预测模型（HINT、TrialBench）AUC 约 0.60–0.77，回答的是另一个问题，不能替代运行特征。

### 2.5 大模型智能体加统计引擎：败在假设和规格，不败在算术

| 系统 | 语言变成什么 | 谁算 | 人在哪 | 实测 |
|---|---|---|---|---|
| PowerGPT（预印本） | 接口调用的 JSON | R | 问效应量等；最终分析要人 | 样本量正确率 94.1%，**对照是人用教科书、软件、搜索且不用 AI**，55.4%；每题 4.0 对 9.3 分钟。没有裸模型对照 |
| EmulatRx（同行评议） | 方案、SQL | 代码跑 Cox 等 | 查询由人给；映射不上时交给临床代理，专家可介入 | 概念解析召回 98.9%；与随机试验只有定性比较；同一案例队列 1,153 与 2,306 人 |
| ClinAgent（**单作者预印本**） | ADaM（试验分析数据集标准）规格 | 工具层 | 未做对照 | 72.1% 是一个合成二期研究上的推导准确率，不是智能体总准确率；**没有确认它就是 Biology Methods and Protocols 那篇** |
| jinko-skills（厂商） | `reproduction-spec.json` | 平台 | **批准假设，确认后才跑** | 无公开基准 |
| Veristat、Cytel、Certara（厂商） | 规格或 R 代码 | 各自引擎 | 统计师审或用户负责 | 无独立评价 |

骨架一致：语言到类型化请求，再到确定性引擎，再到文字解释。差别只在中间那一下，是问、假设还是拒绝。

失败的位置按证据排序（排序是我们的综合，没有单一研究同时测全部）：方法适用性和假设最差，StatQA 最佳 64.83%，主要错在适用性，P-Bench 上 GPT-5.4 难题结论对 58.3%，连分析也对只有 30.5%；其次是规格和参数；再次是结论对分析错，难以发现，JMIR 2026 称外行看不出；代码跑不通常见但看得见，BioDSA-1K 可执行率 58%–87%；算术最小，Sebo 和 Wang 测得裸模型样本量偏差最多约 15%（另有一例 26%）。

问还是假设：能问比不能问好，但问多了没用。Ask or Assume 的通过率是不能问 54.80%、能问 61.20%、把检测和执行分开 69.40%、完整说明 70.80%。LHAW 里多数情况问了也回不到完整说明的水平，最常见失败是一次问好几件事。ClarifyBench 用工具参数域判断该问什么，问题减少 1.5–2.7 倍。模拟问诊 MediQ 里要模型多问反而让准确率相对降了 11.3%（只见摘要）。这些都来自编程或工具任务，**没有任何研究在临床统计智能体上测过提问数、假设回显或表单对对话**，所以对我们是合理推断，不是已证结论。

### 2.6 文献参数抽取：漏得多，编得少

| 任务 | 结果 | 来源 |
|---|---|---|
| 研究设计、人群等描述性字段 | 准确率 0.74–0.95 | TrialMind |
| 结果数字 | TrialMind 0.42；Yun GPT-4 二分类 0.655、连续 0.487 | 同行评议会议 |
| 统计字段召回 | 0.21–0.45，定制提示后 0.38–0.76 | Li（预印本） |
| 错误类型 | **缺失占 87.8%**，错值 10.3% | Li |
| 模型初稿加人核对 | 91.0% 对纯人工 89.0%，每篇省 41 分钟 | Gartlehner（摘要页，二手来源有出入） |
| 引文重复性 | 值 90% 一致，引文只有 46% | Elicit 研究 |
| KM 曲线数字化 | 合成图中位绝对误差 0.005；重度删失时中位值 6.31 对 8.2 | KM-GPT（预印本，无同行评议结果） |

含义有两条。缺失是头号错误，所以“这篇没报告”应该是一等结果，不该硬凑一个值。模型给的引文不可信，必须用代码比对原文，这件事我们已经做到数值和单位这一层，走在前面。

### 2.7 六类共用的逻辑

| 步 | 做什么 | 匹配 | 人群 | 对照 | 设计 | 智能体与抽取 |
|---|---|---|---|---|---|---|
| 1 问题与用途 | 决定什么、用到多重 | 找试验还是找患者 | 用途与风险 | 估计目标 | 决策问题 | 澄清意图 |
| 2 路线与上限 | 有什么数据，能说到哪 | 结构化预筛 | 数据等级 | 四道判断 | 公式或仿真 | 问、假设或拒绝 |
| 3 带出处的规格 | 语言变类型化对象 | 入排解析一次 | 来源绑定 | 七要素方案 | 假设卡 | 规格文件、缺失清单 |
| 4 亮出规格 | 默认值和假设可见 | 缺什么 | 假定的相关性 | 无法模拟的项 | 脱落和入组 | 预演和回显 |

| 步 | 做什么 | 匹配 | 人群 | 对照 | 设计 | 智能体与抽取 |
|---|---|---|---|---|---|---|
| 5 确定性计算 | 代码算 | 三值逻辑 | 生成 | 加权估计 | 引擎 | 引擎 |
| 6 自动诊断 | 随结果一起出 | 未知占比 | 校准与验证分开 | 平衡、E 值 | 零效应、敏感性 | 读回结果 |
| 7 结果分级 | 能说到哪 | 符合/不符合/证据不足 | 用途上限 | 估计/受限/基准/不可估计 | 权衡表 | 结局类别 |
| 8 留档可改 | 版本不覆盖 | 改判 | 版本 | 冻结 | 版本比较 | 快照 |

## 3. 模块怎么组织：一条线，四种走法，零个步骤条

### 3.1 端到端只有一条线

| 步 | AI 和代码做什么 | 语言归模型 | 精确归代码 | 用户看到 |
|---|---|---|---|---|
| 1 听问题 | 判断是四件事里的哪件，用途默认探索 | 意图 | 用途上限 | 一句话开始，不用先选 |
| 2 定路线 | 看有什么数据和证据，说清能回答到哪 | 适用性判断 | 数据等级判定 | 回复第一句：“能做到什么，不能说什么” |
| 3 填规格 | 查文献和登记库，缺的记下，不凑 | 抽取、理解 | 逐字核对数值和单位 | 不需要填任何东西 |
| 4 亮规格 | 预演：列出全部假设和默认值 | 挑出决定结论的几个 | 归一化、算默认值 | 假设和来源，**不等回复**，一句话能改 |
| 5 算 | 引擎逐作业运行 | 不参与 | 全部 | 活动条（工作台分支提供） |
| 6 带诊断 | 零效应、E 值、平衡、未知占比一起出 | 解释 | 全部 | 和结果放在一起 |
| 7 给类别 | 可估计/受限/仅基准/不可估计 | 用人话解释 | 按规则判定 | 类别、限制、缺什么 |
| 8 回路 | 给结果页入口，列入首页；改一句出新版本 | 听懂要改什么 | 新版本，旧结果不动 | 链接、首页列表、结果页的“调整”回到同一段对话 |

**为什么这样组织。** 第一，论文的共同结构就是这样，分歧不在骨架，所以不用为每个任务设计一套。第二，它正好把语言和计算分开，符合“语言归模型，数字归引擎”和“模型不做统计”。第三，它不增加用户的操作：八步里用户主动做的只有第 1 步，改假设时再说一句。第四，它解决了 10 月 25 日之后的结构矛盾，入口搬进了对话，而列表和结果页还按“先建研究”设计。

**这不是七步流程的复活。** 八步写在 AI 的工作规则和工具行为里，页面上没有步骤条。研究页沿用工作台分支的六个结果去向。

**放在哪。** 入口是首页四个示例，点了只往原生输入框填草稿，AI 自己判断任务；不在首页加输入框（简报第 7 节 P0-3 的说法与“不要第二个聊天框”冲突，这里以裁定为准，见第 8.2 节）。“开始”进入通用对话这件事本身不是缺陷，它符合 10-20 和 10-25 的裁定，缺的是回程。对话研究只列在模块首页，不进侧边栏，不改通用项目。根会话不增加任何文字：不加工具、不加技能目录项，工具说明长度不增长。

### 3.2 论文的要求和裁定冲突时怎么办

| 论文或文件要求 | 冲突的裁定 | 这里的做法 |
|---|---|---|
| jinko 确认关卡、人批准补缺假设 | 不加审批和确认 | 亮出、标注、一句话可改，从不等待；AI 已先查证据 |
| UTSW、TrialGPT 等每个部署都有人复核 | 不加强制人工裁决；招募已移除 | 结果是研究结果，不联系任何人；未知不排除、不符合也留在列表；改判可选 |
| FDA、RCT-DUPLICATE 先冻结再看结局 | 探索用途不加仪式 | 封存机制保留，指定分析及以上才启用；探索时在回复里说明方案是后写的 |
| FDA、CDE 的适用性判断放在最前 | 不加硬关卡 | 记录适用性，没记录时提醒模型补；代码能判的触发项给“受限”；真缺输入才给“不可估计” |
| 从 Charles 审计容易推出“不填完不能保存的表单” | 不要参数表单 | 由模型和文献填，代码回显默认值，缺的以提示和标签呈现 |
| 报告规范要求列全假设和诊断 | 10-10：不堆用户可见的提示和后台标注 | 结果页一块“前提”，3–5 条，其余折叠（5.2 节） |
| E20 的 11 项报告 | 10-25 重置：不强制方案 | 数据都留着，用户要时才导出（D7） |
| RECTIFIER 等大型评测 | 业主反对过度测试 | 一次按患者分组的匹配评测，其他靠确定性测试（第 5.5 节） |

### 3.3 四种走法

| 任务 | 路线怎么定 | 规格和计算 | 默认带出的东西 | 给用户的结论形式 |
|---|---|---|---|---|
| **匹配** | 一位患者找试验；一个试验找一批人 | 代码筛状态、年龄、性别、地区并合并三个登记库（模型写检索词）→ 每个试验解析一次并按记录哈希复用 → 按条件从长病历定位片段，模型取事实带原文，代码复核引文 → 三值逻辑判定 | 决定比例、未知及原因、覆盖了哪些登记库和截至日期 | 排序名单，每条有依据；“符合”不等于推荐；不联系任何人 |
| **人群与患者** | 只有文献：文献人群；有个体数据：真实队列或合成；要个体预测：已发表模型代入 | 绑定基线表 → 生成 → 与输入对照（不叫校准）→ 有第二份分布时做独立对照 | 相关性来源、再抽样范围、“人群相似性未验证”、模型的适用人群 | 标“合成”和用途上限；个体预测标“未经本地校准” |
| **对照** | 四道判断：随机？两方个体数据？自然史和效应？能否锚定？ | 目标试验记录 → 数据适用性 → 看重叠和平衡（结局之前）→ 估计 | 有效样本量、E 值、平衡表、目标人群；提议阴性对照 | 四类之一：估计/受限/仅基准/不可估计 |
| **设计** | 公式能解就用公式 | 假设卡（标重要或现实）→ 公式 → 基准设计并列 → 仿真（含零效应） | 蒙特卡洛误差、一次一项敏感性、默认值、效应折减后的把握度 | 权衡表，一句建议及其依据；不选“最佳”，不说药有效 |

## 4. 差距：引擎已经够严，缺的是两头

路径简写：`S` = `OpenScience/apps/server/src`，`W` = `OpenScience/apps/web/src`，`D` = `OpenScience/packages/domain/src`，`M` = `OpenScience/runtime/mcp/evimed-research`，`C` = `OpenScience/capabilities`，`G` = `项目代码/vcr-engine/R`，`E` = `OpenScience/evals`。行号指 `github/main` 77ba0a436。

### 4.1 已经做对的，不要动

这些比多数论文系统严：未知、不适用和判定分开，未知不算排除（`S/vcrMatching.mjs:889-902`）；否定事实防护，引文写入和判定时都复核（`S/vcrMatching.mjs:261`）；判定由代码做（`S/vcrMatching.mjs:952,1043`）；模型写不了结果和计数（`M/vcr_platform.py:244`）；数值、单位和引文锚定（`S/vcrEvidence.mjs:325-395`）；图上的数由数字化工具量（`M/vcr_platform.py:344-364`）；公式先算、仿真复核，蒙特卡洛误差可见（`S/vcrOrchestrator.mjs:1407,1444`、`G/design_simulate.R:535-600,628-660`）；人群质量三维度（`G/quality.R`）；非锚定 MAIC 封顶“受限”（`G/maic.R:17-18,168`）；模型卡上的“未验证可移植性”（`G/model_prognostic.R:87,94`）；结果到假设的血缘（`S/vcrJobs.mjs:883-941`）。

### 4.2 按八步看差距

| 步 | 匹配 | 人群 | 对照 | 设计 | 智能体 |
|---|---|---|---|---|---|
| 1 问题与用途 | 够 | 用途默认探索；模型评估记录不强制 | 够 | 隐藏研究无问题时 `aim` 为空（`S/vcrViewsTabs.mjs:825`） | 够 |
| 2 路线与上限 | 没有平台召回阶段，模型自由搜（`C/vcr-matching/SKILL.md:165`） | 上限由代码算，**够** | 适用性只在技能里（`C/vcr-analysis/SKILL.md:241`），算出 HR 可以没有记录 | 公式优先，**够** | 只有“先查证据”规则 |
| 3 规格 | 解析按研究存，新研究重解析（`S/vcrCandidateTrialStore.mjs:139,165`）；长病历没有按条件定位（`C/vcr-matching/SKILL.md:86-92`） | 来源绑定，**够** | 目标试验只有自由文本一项（`D/vcrScenarioSchemas.mjs:165-168,383`） | 卡上没有“重要/现实”角色（`S/vcrGateway.mjs:840-850`） | 技能约 79,000 字才开始；文献没有必填清单 |
| 4 亮规格 | 缺失原因不在读回里 | **没给矩阵就按独立处理，且无标签、无敏感性**（`G/population.R:121,379-382`） | 目标试验记录形状不一致（下述） | **脱落默认 0 且不显示**（`D/vcrScenarioSchemas.mjs:260,270,775`） | 没有预演（`M/vcr_platform.py:298,1063-1095`） |
| 5 计算 | 匹配写入即判，没有作业（`S/vcrGateway.mjs:1044`） | 够 | 够 | 够 | 够 |

| 步 | 匹配 | 人群 | 对照 | 设计 | 智能体 |
|---|---|---|---|---|---|
| 6 诊断 | 没有决定比例 | 校准和验证未分开；文献人群无独立对照 | E 值、阴性对照默认不跑（`S/vcrOrchestrator.mjs:1159-1166`） | **普通两臂没有测到 I 类错误**（`:1444`，Simon 已跑两种情况 `:1430-1437`）；没有基准设计；敏感性只按请求跑 | 读回只是一句规则 |
| 7 分级 | 够 | 够 | 没有“仅基准”类（`D/vcrVocabulary.mjs:624-645`）；非劣效和中等效应不触发；SMD>0.1 直接不可估计（`:626,917`） | 不说明为什么没有 assurance（`S/vcrOrchestrator.mjs:700-711`） | 够 |
| 8 回路 | **没有任何通往结果页的路径** | 首页不列 | 首页不列 | 首页不列 | 工具答复没有链接（`M/vcr_platform.py:1141-1212`） |

“算了但没显示”是另一类，10-10 裁定说虚拟临床研究的每项功能都要真正生效，所以这些也算缺陷：MAP 先验的运行特征表没有视图读它（`G/engine.R:1553`），而且默认 5,000 次（`G/engine.R:1524`），`vcrReplicatesForJob` 不应用下限（`S/vcrJobs.mjs:280-288`）；MAIC 的目标人群和未调整修饰因子只在诊断里（`G/engine.R:1419,1432`）；文献人群的“相关性为假定、可移植性未验证”不上页（`S/vcrJobs.mjs:821-822`）；设计页不列偏倚和覆盖率（`S/vcrViewsTabs.mjs:881-883`），数据生成方式也不写入组和脱落（`:829`）。

真正没有的能力：基准设计、非比例效应和 MaxCombo（`D/vcrScenarioSchemas.mjs:239,1320`）、随机加借用的混合设计（`D/vcrVocabulary.mjs:680`）、文献人群的独立验证、已发表模型的本地校准（`G/model_prognostic.R`）、按条件取证据。

文字与代码不一致：`C/vcr-analysis/SKILL.md:196` 说 `model_comparator` 未实现，代码已运行（`S/vcrOrchestrator.mjs:1345`）；`C/vcr-evidence/SKILL.md:120` 说论文正文核对不了，`:26-38` 和 `S/vcrEvidenceSources.mjs` 已能核对；技能示例的 `targetTrial` 是数组（`C/vcr-analysis/SKILL.md:231-235`），网关和视图读顶层对象（`S/vcrGateway.mjs:1311,1316`、`S/vcrViewsTabs.mjs:743-746`），**所以技能教的写法进得了引擎，到不了页面**；`G/reconstruct.R:20-24` 说没有风险表也能重建，校验器却必填（`D/vcrScenarioSchemas.mjs:151,570`）。

### 4.3 断点复核，以及简报修法里的两个坑

简报的断点全部成立（`W/app/virtual-research/VcrHomePage.tsx:332`、`W/components/vcr/useGeneralResearchDraft.ts:13-16`、`S/vcrGateway.mjs:2252-2254`、`S/vcrStore.mjs:428-440,551`）。补充三点：作业完成时除站内信还有轻提示（`W/components/vcr/useVcrFinishedToasts.ts:81-85`）；**患者匹配写入即判，没有作业，所以连通知也没有**；从通知进入后，只做了匹配的研究，总览页会要求“说明研究问题”（`W/components/vcr/tabs/OverviewTab.tsx:48`、`W/components/vcr/VcrStates.tsx:185`），这一点是读代码推断，没有渲染过。

**坑一：不能放宽 `listStudies`。** 同一个 `GET /api/vcr/studies` 同时被侧边栏、项目设置、知识库分组、模板选择和参考试验选择读取（`W/components/vcr/useVcrProjectIds.ts:79-87`、`W/components/vcr/VcrKnowledge.tsx:540`、`W/components/vcr/VcrReferenceSearch.tsx:46`）。隐藏研究的 `projectId` 就是用户的通用项目。如果把它放进 `hom`

`e.studies`， `useVcrProjectIds` 会把这个通用项目算进 `tasks`，而知识库的 `W/components/sources/useProjectGroups.ts:52` 会把 `tasks` 从可用项目里去掉，通用项目就从知识库的选择里消失了；模板和参考试验的研究选择器也会多出这些隐藏研究。侧边栏这一处靠 `purpose !== "task"` 过滤，读代码暂时不受影响，但它和其他读取方共用同一份数据。这正是 PR #17 审查修掉的那类缺陷：研究占用通用项目。另外每条研究要跑约 11 个查询（`S/vcrService.mjs:556-569`），列表最多 500 条，会拖慢所有读取方。**正确做法是新增独立字段 `conversationStudies`，用轻量摘要，只有 `VcrHomePage` 读它**（F1）。

**坑二：回复里放一个路径不一定能点。** 对话跑在自己来源的内嵌页里，普通相对链接会解析到那个来源。外壳的跳转是闭合词表（`W/app/routes/RuntimeUiFrame.tsx:844-854`），已有 `open-item`、`open-source` 这种带严格校验的消息（`:952-964`）。所以要么加一条同样校验 `studyId` 和页签的消息，要么用 `OPEN_SCIENCE_PUBLIC_URL`（`S/config.mjs:2009`）给绝对地址。内核对这种链接怎么渲染我没有验证，必须在真实对话里试一次（F3）。

## 5. 整改方案：44 项，四期，按收益排序

排序依据是用户或答案正确性能得到多少，不是论文提得多不多。**S** 不到一天，**M** 几天，**L** 一周以上，都是粗估。“合并后”表示文件被工作台分支改过。**全部项目都不新增拦截点**：新东西都是标签、提示或默认带出。改变判定的只有三处：A7 把部分结果标为“受限”，结果照给；A10 和决定 2 把原来的拒绝放宽成给结果并标受限。

### 5.1 Phase 0：接通回路（6 项，约一周）

不做完这一期，后面的改进用户都看不到。

| # | 改什么 | 为什么 | 在哪 | 大小 | 怎么算做完 |
|---|---|---|---|---|---|
| F1 | 首页列出对话里的研究：新字段 `conversationStudies`，独立查询（`scope='conversation'`、已有对象、最新 50 条、轻量摘要），`home.studies` 不变 | 简报实测断点；放宽原查询会复现 PR #17（4.3 节） | `S/vcrStore.mjs:548` 附近，`S/vcrService.mjs:543-600`，`W/app/virtual-research/VcrHomePage.tsx`（后两个合并后） | S+S | 测试：有结果的对话研究出现在新字段、不在 `studies`；无对象不列；**`useProjectGroups` 测试断言默认项目仍在 `applicable`**；侧边栏无变化 |
| F2 | 研究用第一句话命名，通知同步，不再叫“对话研究” | 通知写“研究「对话研究」” | `S/vcrStore.mjs:428-440`，`S/vcrGateway.mjs:2252`，`S/vcrNotify.mjs:262` | S | 测试：首写入后名字来自首句，定义写入可覆盖 |
| F3 | 每个终态工具答复和匹配写入都带服务端生成的结果入口，按任务指向页签；规则要求回复给链接。不让模型自己拼路径（jinko 的规则也是地址只能来自平台） | 结果页到不了；匹配连通知都没有 | `M/vcr_platform.py:1141-1212`，`S/vcrGateway.mjs:1044,2291`，`W/app/routes/RuntimeUiFrame.tsx:844-964`，`C/vcr-protocol/references/operating-contract.md:59`；现成先例 `S/vcrService.mjs:965` | S-M | 测试：答复含入口；非法 id 被外壳拒绝；真实对话四任务各点开一次到正确页签 |

| # | 改什么 | 为什么 | 在哪 | 大小 | 怎么算做完 |
|---|---|---|---|---|---|
| F4 | 结果页按实际内容落地：只做匹配的研究进“匹配”，不再要求“说明研究问题” | 新用户点进来第一屏是错的 | `W/components/vcr/tabs/OverviewTab.tsx:48`，`W/components/vcr/VcrStates.tsx:185`，`W/components/vcr/VcrResearchProgress.tsx:29-41`（合并后） | S-M | 组件测试：只有匹配结果的研究显示结果；进度卡不提人群定义 |
| F5 | 首页减负：任务选择改成四个示例（只填草稿）；文案换成“说清什么就能开始”（用简报第 7 节的四句）；空状态改成真话：“在对话里说明要研究什么，AI 保存第一项结果后，研究会列在这里。”；“参考试验、人群定义、模型与参数”从并列视图退到结果的依据和对话引用，旧链接和已存对象保留 | 把统计字段念给用户，和设计相反；分支的空状态依然不真；10-20 已说这些是上下文工具 | `W/components/vcr/frameVcrOptions.ts:51-54`，`VcrHomePage.tsx`（合并后） | S-M | 文案测试；页面不出现“显著性水平”等字段名；旧地址仍能打开 |
| F6 | 确认“调整”从隐藏研究回到原对话，一句话改假设出新版本 | 这次没有追到解析器返回哪段会话 | `S/vcrService.mjs:805-814`，`W/app/virtual-research/VcrStudyPage.tsx:249-257` | S | 测试；一次真实对话走完“改一句→新版本→旧结果还在” |

**不能证明的：** 用户真的觉得顺了。Phase 0 只保证路径通。

## 5.2 Phase 1：亮出悄悄生效的假设（15 项，约两周）

**这一期的呈现规则，优先于下面每一项的“上页”。** 10-10 裁定不要堆用户可见的提示和后台标注，标签加多了也会重现“看不懂”。所以：

- 结果页只有一块“这个结论的前提”：决定结论的 3–5 个假设，写值、来源、是否默认，其余折叠，一句话就能改。
- 不加横幅，不加通用免责声明。每条前提都要带一个值，或者一个能改的动作。
- “没写”先提醒模型，通过工具答复让它当轮补上。补不上又影响结论时，才进“前提”。
- 科学假设和参数来源可以给用户看（10-20 裁定保留了判断参数所需的来源）；运行记录、校验过程这类后台内容仍然不给。

做完的统一标准：只给 6 个值的两臂生存设计，结果页“前提”不超过 5 条，其中有脱落率和它的来源或默认标记。

| # | 改什么 | 为什么 | 在哪 | 大小 | 怎么算做完 |
|---|---|---|---|---|---|
| A1 | **所有设计默认多跑一个零效应情景**，照 Simon（单臂两阶段设计）的写法。代价不小：零效应下限 2 万次是备择 5 千次的 4 倍，引擎又只有一个计算队列，所以先出结果，零效应排在后面补上，用户不用等它 | E20、FDA 2019、Granholm 都要；现在普通两臂没有测到 I 类错误，只靠技能一句话 | `S/vcrOrchestrator.mjs:1430-1444` | S | 作业测试：两臂结果含 `simulation_null`，带 I 类错误和蒙特卡洛误差；公式已可解时标“复核” |

| # | 改什么 | 为什么 | 在哪 | 大小 | 怎么算做完 |
|---|---|---|---|---|---|
| A2 | **默认值全部回显**：诊断、工具答复（`applied`）、结果页假设条同时显示，“脱落率 0（默认）”必须看得到 | 简报第 3.2 节；ICH M15 要求识别假设；jinko 不许悄悄补 | `G/engine.R`，`M/vcr_platform.py:1141-1212`，`S/vcrViewsTabs.mjs:829`，`W/components/vcr/tabs/TrialTab.tsx:364`（合并后） | S+S | 只给 6 个值的两臂生存设计：答复和页面都列出全部默认值 |
| A3 | **未给相关矩阵时，写明“假设相互独立”**，加来源行 | 联合分布是汇总数据最弱的一环（SAS C）；现在无标签 | `G/population.R:121,379-382`，`D/vcrScenarioSchemas.mjs:494-495` | S | R 测试：无矩阵时有来源行；页面可见 |
| A4 | 文献人群三个标签上页；`parameterDraws` 默认多抽几次，报范围 | 校准不等于验证；Allen 建议重抽；现在默认 1 次 | `S/vcrJobs.mjs:821-822`，`D/vcrScenarioSchemas.mjs:496`，`G/population.R:377`，`W/components/vcr/tabs/PopulationTab.tsx`（合并后） | S | 页面显示相关性为假定、相似性未验证、抽样范围 |
| A5 | E 值在主要估计后自动算，含置信限；任何 T2（有治疗和结局的个体数据）估计都由 AI 提议阴性对照（需要真实列，所以问一句合理） | VanderWeele、TARGET、FDA 都要求敏感性随结果报告；现在默认不跑 | `S/vcrOrchestrator.mjs:1159-1166`，`C/vcr-analysis/SKILL.md:245` | S | 加权 Cox 结果自动带 E 值；措辞遵守 Lipsitch（“未发现”，不说“没有偏倚”） |
| A6 | 目标试验记录统一成一个形状，闭合七要素，每项标精确/近似/不能；没写时工具答复提醒模型补，不拒绝 | Hernán、TARGET；0.93 对 0.53；现有形状不一致是真缺陷 | `D/vcrScenarioSchemas.mjs:165-168,383`，`S/vcrGateway.mjs:1311,1316`，`S/vcrViewsTabs.mjs:743-746`，`C/vcr-analysis/SKILL.md:231-235` | S+S | 技能示例往返后出现在页面；不能模拟的项进“前提”；无记录时工具答复有提醒且结果照给 |
| A7 | 对照结果带一条“适用性记录”，模型写，进“前提”，没写时工具答复提醒模型补；代码能判的新触发项（非劣效目的、没有时间零点规则）只给“受限”并写原因，现有“不可估计”规则不变 | FDA 脚注 14、EMA、CDE 都把适用性放最前；**不做硬关卡**（10-10）；新检查按原则 4 先作标签 | `D/vcrVocabulary.mjs:624-645`（合并后），`S/vcrViewsTabs.mjs:683-693,736` | S | 测试：外部对照加非劣效目的得“受限”和原因；无记录的 HR 仍交付，工具答复提醒模型补 |
| A8 | 结果多一类“仅基准”：文献曲线、非锚定 MAIC、模型预测 | 四类划分是这次从各文件归纳的；Unlearn 的流程也把非定制基准单列；避免基准被读成效果估计 | `D/vcrVocabulary.mjs`（合并后），`S/vcrViewsTabs.mjs` | S | 三类路线都显示“仅基准” |
| A9 | MAIC 显示目标人群和未调整修饰因子；非锚定固定一句“残余误差大小未知” | TSD 18 建议 3、6；数据已在诊断里 | `G/engine.R:1419,1432`，`S/vcrViewsTabs.mjs`，`W/components/vcr/tabs/ComparatorTab.tsx`（合并后） | S | 页面出现两行 |

| # | 改什么 | 为什么 | 在哪 | 大小 | 怎么算做完 |
|---|---|---|---|---|---|
| A10 | KM 重建记录信息级别（四档）。无风险表时不拒绝：生存概率和中位标“受限”；风险表和总事件都缺时，HR 给“不可估计” | Guyot 的误差从 0.017 到 0.198，真实 1.5 可重建成 0.32–7.11；现在缺总事件时悄悄跳过检查（`G/reconstruct.R:220`） | `D/vcrScenarioSchemas.mjs:151,570-571`，`M/vcr_platform.py:425-439`，`G/reconstruct.R` | S+M | 四档各一个测试；通过时也显示级别 |
| A11 | MAP（把历史对照数据合成一个先验）的运行特征：应用重复次数下限，把表画出来 | CDE 第 6 号 把假阳性放在首位；现在 5,000 次且没人读 | `S/vcrJobs.mjs:280-288`，`G/engine.R:1524,1553`，`ComparatorTab.tsx`（合并后） | S+S | 零漂移行不少于下限、带误差；页面可见 |
| A12 | 设计页补偏倚、覆盖率、数据生成的入组和脱落、重复次数的理由 | E20 第 3、6 项；Morris 回顾显示多数论文不报 | `S/vcrViewsTabs.mjs:829,881-883`，`G/design_simulate.R:73-74`，`TrialTab.tsx:471-477`（合并后） | S | 列和文字出现；引擎已算好，不改数字 |
| A13 | 假设卡加效应角色：重要差异/现实预期，没有时工具答复提醒模型补 | DELTA2；效应是最常错的输入 | `S/vcrGateway.mjs:840-850`，`D/vcrVocabulary.mjs:706` | S | 卡上有角色；缺时提醒模型；不拒绝 |
| A14 | 没有 assurance（对效应不确定性积分后的成功概率）时说明原因 | 现在悄悄不出现 | `S/vcrOrchestrator.mjs:700-711`，`S/vcrViewsTabs.mjs:995` | S | 无预测分布的卡片显示原因 |
| A15 | 修掉技能与代码的矛盾（第 4.2 节四处） | 模型照错的说明做 | `C/vcr-analysis/SKILL.md:196,231-235`，`C/vcr-evidence/SKILL.md:120` | S | 四处一致；能力包相关测试通过 |

**不能证明的：** 这一期让结果更诚实，不能证明数字更准。引擎的数值正确性依赖现有 R 测试，这份方案没有重跑。

### 5.3 Phase 2：少走弯路，补匹配短板（15 项，约三周）

| # | 改什么 | 为什么 | 在哪 | 大小 | 怎么算做完 |
|---|---|---|---|---|---|
| C1 | `action: validate`：返回归一化规格、默认值、重复次数、粗估耗时，不进队列、不等人 | jinko 预演的非等待版本；现在校验只在启动时 | `M/vcr_platform.py:298,1063-1095` | S | 测试；根会话工具说明长度不增长 |
| C2 | 字段标“研究事实”或“可默认”，由结构推导；规则加一句：只问会改变下一步计算的，一次一件 | ClarifyBench、LHAW；检测缺什么是模型弱项，放代码 | `M/vcr_platform.py:960-1028`，`C/vcr-protocol/references/operating-contract.md:35-37` | S+S | `shape` 有角色；一段欠明确的真实对话只问一件事或带标注继续 |
| C3 | 技能按任务拆分，纵向和打包内容放到引用里 | 设计任务约 79,000 字才开始；SkillsBench 说聚焦技能更好（只见摘要） | `C/vcr-analysis/SKILL.md`（422 行）等 | M | 脚本量：设计任务读取字数明显下降；四份副本测试通过 |

| # | 改什么 | 为什么 | 在哪 | 大小 | 怎么算做完 |
|---|---|---|---|---|---|
| C4 | 每类任务一份最小模板，常见路径缺省由代码补 | 简报记录的 28、47 次调用，含字段被拒 | `M/vcr_platform.py`，`D/vcrScenarioSchemas.mjs` | M | 模板通过校验器；真实对话里没有字段名拒绝 |
| C5 | **基准设计自动并列**：任何分组序贯或 Simon 旁边自动有固定样本一行 | E20 明确要求；现在只靠技能 | `S/vcrOrchestrator.mjs:1407-1444`，`C/vcr-analysis/SKILL.md:251` | S-M | 作业测试；页面标“基准” |
| C6 | **一次一项敏感性**：公式阶段自动扫效应、对照率、脱落、入组；加一行“效应按已发表的计划—实测差距折减后的把握度”（例如肿瘤 0.66→0.72，要先用 rpact 核） | 效应影响是平方级；10.1 对 1.4；现在只按请求 | `S/vcrOrchestrator.mjs:1471`，`G/design_simulate.R`，`TrialTab.tsx`（合并后） | M | 公式结果带排序表；不增加仿真负担 |
| C7 | 默认比较目标取自 α 和目标把握度；规则要求 AI 给一句建议并说依据哪条约束；平台不替人选 | FDA 2019：选择归申办方；我们的推论是建议要说明依据的是约束还是效用，FDA 2026 草案也区分这两种 | `S/vcrViews.mjs:967`（合并后），`C/vcr-analysis/SKILL.md` | S | 权衡图默认出现；回复有建议和依据 |
| C8 | 文献抽取按参数列必填项，**“论文未报告”是一等结果** | 缺失占 87.8%，现在漏了看不见 | `S/vcrEvidenceSources.mjs`，`S/vcrGateway.mjs` | S-M | 缺 SD 的来源显示“未取到”，不填值 |
| C9 | 问周期时默认用入组模型，不用均匀假设 | Walters 中位每中心每月 0.92 人且分散 | `C/vcr-analysis/SKILL.md` | S | 技能一行；对话走到该方法 |
| M1 | **候选读取动作**：合并三库、代码筛状态年龄性别地区、封顶、去重、报各库失败和未覆盖，模型写检索词 | TrialGPT 关键词把召回从 50.0% 提到 86.2%（合成队列）；现有多库搜索只给页面用 | `S/vcrEvidence.mjs:1250-1297`，`M/vcr_platform.py`；根工具 `clinical_trial_search` 不动 | M | 测试：合并、去重、封顶、部分失败仍有结果且写明；回复说明覆盖范围和截至日期 |
| M2 | 入排解析按“登记库+记录哈希”在账户内复用 | PRISM、UTSW 都解析一次；现在换研究就重解析，条件也没绑到哈希 | `S/vcrCandidateTrialStore.mjs:139,165` | M | 第二个研究不再解析；哈希变了才重解析 |
| M3 | 解析抽查用例 | PRISM 手查 50 个试验：漏题 1%、错题 2%、布尔逻辑约 89%；我们没有这一项 | `E/vcr-matching` | S | 用例进测试，确定性比对 |
| M4 | 按条件定位病历片段：代码按词在部署内定位，模型只看片段，引文仍复核 | UTSW 每条 30 个片段，论文一致不整份给 | `C/vcr-matching/SKILL.md:86-92`，`S/vcrMatching.mjs` | M | 合成长病历：定位命中；否定防护测试仍过 |
| M5 | 排序加“已决定比例”；读回带缺失原因和简短依据；补决定百分比；登记状态写截至日期 | 少解析的试验现在可能排在前面（`S/vcrPatientTrials.mjs:257-265`）；未知要和准确率并报 | `S/vcrPatientTrials.mjs:257-265,618`，`S/vcrMatching.mjs:897-902`，`D/vcrVocabulary.mjs:136-140` | S | 排序测试；读回含原因和引文 |
| M6 | 没有登记原文的条件按“未知”算，原因写“缺登记原文” | 10-25 审查发现 ChiCTR 经接口只有列表、条件不报警；这次没有找到已修标记，要先复核 | `S/vcrGateway.mjs` 候选写入处，`S/vcrEvidence.mjs:1195,1240` | S | 测试：无原文的条件不会判成满足或不满足 |

**不能证明的：** 工具调用次数下降说明模型少走弯路，不说明答案更对；M1 的测试证明合并逻辑对，不证明覆盖够。

### 5.4 Phase 3：按需求加深（8 项，有真实需求再动）

| # | 改什么 | 什么时候动 | 为什么 | 在哪 | 大小 | 怎么算做完 |
|---|---|---|---|---|---|---|
| D1 | 治疗组分段 HR 加 MaxCombo，只放在仿真里 | 有生存终点方案比较的用户 | Zhao；不换默认，log-rank 常有竞争力 | `D/vcrScenarioSchemas.mjs:208-219,239,1320`，`G/design_simulate.R:290,302` | M | 延迟和交叉情景能跑；与公开参考值（`simtrial`、`gsDesign2`）交叉核对 |
| D2 | `population_check`：用第二份已绑定基线表做独立对照；把“校准条”改名为“与输入对照” | 文献人群开始用于设计决策 | FDA 第 5 类证据；校准不是验证 | `W/components/vcr/patients/CalibrationStrip.tsx:9-24`，`S/vcrRows.mjs:623-631`，新作业 | M（改名 S，可提前） | 两份基线表的对照结果上页，标“未覆盖的不算验证” |
| D3 | 已发表模型的本地校准（截距和斜率，复用现有评估）；模型卡加 TRIPOD 字段 | 有人带结局数据来 | STRATOS、TRIPOD+AI | `G/model_prognostic.R`，`D/vcrForecastEvaluation.mjs:59`，`S/vcrModelDocuments.mjs:187-205` | M | 截距和斜率有 R 测试；事件和非事件不足时只报截距 |
| D4 | 批量匹配：结构化预筛、逐人抽取、可续跑、事先说预计费用 | 有表格型用户 | UTSW 每人约 $0.12；现在抽取挤在一轮对话里 | `C/vcr-matching/SKILL.md:94,118,130`，`M/vcr_platform.py:311` | L | 中断后续跑不重算；取消保留已完成部分；开始前说费用 |
| D5 | 设计网格各真值共用随机流 | 用户比较细微差异 | Murphy 方差降 74%–94%，但同一文说要在自己模型里测 | `G/engine.R:1832`，`G/design_simulate.R:743` | M | 测试比较有无共用随机流的方差，并删除 `no_common_random_numbers_between_cells` 标签 |
| D6 | 有日期列时加入组年份平衡行 | 外部对照用户 | 结局漂移是两大偏倚之一 | `G/engine.R:1190-1194`，`S/vcrViewsTabs.mjs:696-703` | S-M | 有日期列的数据出现这一行；没有时不报错 |
| D7 | 任一结果可导出短记录（含示例单次试验） | 有人要报告 | E20 第 9 项；10-25 重置后只按请求 | `S/vcrOrchestrator.mjs:232-236`，`D/vcrContracts.mjs:370` | M | 导出含假设、种子、版本和一个示例试验 |
| D8 | 清理无调用者的代码：确认后删 `vcrNext`（分支上也没有调用）、`VcrLiteratureSource`、`VcrReconstructionInput`、`editVcrCard` 客户端、`createVcrStudy`/`startVcrStudy` 客户端 | 合并后立刻做 | “没用的和历史的都不留” | `D/vcrNext.mjs`，`W/lib/vcrClient.ts:2335,2355,2468` | S | 类型检查和测试全过；路由是否保留先确认无外部调用 |

### 5.5 验证：够用就好，并且说清证明不了什么

评测不是发版条件。普通修复过了确定性测试就可以上线。

| 检查 | 做法 | 能证明 | 不能证明 |
|---|---|---|---|
| 确定性测试 | 每项自带；R 改动跑 `bash tests/run_all.sh` | 代码按规格工作 | 用户体验、临床正确 |
| V1 真实对话 | Phase 0 后走 4 段（每任务一段，真实 DSH + DeepSeek，一次性账号，用完删除；走原生输入框、不标 `automated`，因为平台不把 automated 运行的消息当作人给的病例（`S/vcrPatientContext.mjs:30,62`），匹配会走不通），加 2 段欠明确的；之后只重测受影响的任务 | 回路通、回复有假设和链接、一句话能改 | 统计意义上的成功率；**一次通过不是比率** |
| V2 匹配评测 | 一次，冻结后不再调（详见下） | 这个数据集上的逐条准确率 | 中文病历、检索召回、肿瘤、临床有效 |
| V3 原生对照（可选） | 4 个任务加 2 段欠明确，平台和原生各跑一次，共 12 段 | 肉眼可见的差异方向 | 没有重复采样，不能说显著更好 |

**V2 的设计。** 用 n2c2 2018：真实病历，已按患者分 202 训练、86 测试。只在训练集上调，测试集只跑一次。区间按患者整块重抽样估计（cluster bootstrap）。报告每条标准的准确率、未知占比和“符合判成不符合”的比例，未知不从分母里剔除；n2c2 的金标只有符合和不符合，所以未知要单独统计。按我们的估算，比例 0.9 附近要有 ±5 个百分点至少要约 139 个独立单位；86 位患者在患者层面约 ±6 个百分点（我的算术，非发表数字），而且同一患者的条目相关，实际更宽。局限要写明：英文、13 条固定条件、没有登记库检索、标注者 kappa 只有 0.54，所以我们推断，超过约九成的数字分不清是模型还是标注噪声。已有的“12 例 5/12”出自 `docs/ui-ux-audit/2026-10-29-vcr-public-data-first-pass.md:38`（在 `github/main` 上），文件本身明说它是诊断用标签一致率，不是总体准确率；`E/vcr-matching/openmed-scorecard.json` 的 0.854 和 0.958 来自合成病例，也写明没有独立临床验证。

## 6. 明确不做的事

| 不做 | 谁建议或可能想到 | 为什么不做 | 替代 |
|---|---|---|---|
| 招募、联系、转诊、中心管理、随访运营 | 多数匹配部署和国内厂商 | 2026-10-25 永久移除 | 匹配是研究结果 |
| 审批、确认关卡、强制人工裁决 | jinko、UTSW、RECTIFIER 作者建议 | 10-10、9-29 裁定；裁定优先 | 亮出、标注、一句可改 |
| 方法目录、参数表单、七步强制流程 | 10-20 旧方向；从审计推出的“必填表单” | 10-25 重置；这条路已证明走偏 | 模型填，代码回显 |

| 不做 | 谁建议或可能想到 | 为什么不做 | 替代 |
|---|---|---|---|
| 第二个聊天框或首页输入框 | 简报 P0-3 | 只有一个原生输入框 | 示例填草稿 |
| 对话研究进侧边栏或占通用项目 | 放宽 `listStudies` 的顺手做法 | PR #17 修掉的缺陷 | 独立字段，只在模块首页 |
| 模型打总分来排序匹配 | TrialGPT 2.0 | 没有逐条审计线索；83.2% 的“符合但不推荐”说明它在预测另一件事；模型可以在文字里说它的看法 | 代码排序，看法标明是模型判断 |
| 语义检索和微调模型 | TrialMatchAI、MatchMiner-AI | 依赖大量标注和运维，先看 M1 是否够 | 三库合并加模型写关键词 |
| 知识图谱 | Massive Bio | 需要持续人工维护，二手报道称每月约 24 小时，且未经独立评价 | 无 |
| 成败预测分 | HINT、QuantHealth | AUC 0.6–0.77，厂商的 85–90% 查不到定义；放在仿真把握度旁边会误导 | 运行特征 |
| 模型生成患者或数据 | 人格模拟 | 方差压缩和反号；模型不做统计 | 引擎生成 |
| 合成患者补对照组 | 虚拟对照 | 相对偏差 76%–133% | 真实外部对照或基准 |
| 机制模型、数字孪生生成器、自训练预测模型 | jinko、Unlearn、DT-GPT | 需要专有数据或机制模型；预测增益小（1.3%–3.4%） | 已发表模型可执行化 |
| 把数字孪生单臂对照说成有随机保证 | 厂商话术 | 识别假设和外部对照一样，无监管资格 | 标“基准”或“受限” |
| BenchExCal 校准 | 学术新方向 | 只有设计论文，无性能结果 | 临界点分析 |
| 恢复 CDE 或 ICTRP | 覆盖面 | 9-29 裁定；这批论文都不研究登记库覆盖，没有提供新证据，**所以不重开，也不列入第 7 节**。代价要写在明处：按一家厂商的估计（去重方法未公开），国内企业发起的干预性试验约 64% 不在 ClinicalTrials.gov 上，ChiCTR 经我们的接口只有列表（`2026-10-25-vcr-ai-native-reset-review.md` §4.5）。若以后中国企业试验的覆盖成为用户的主要抱怨，可行的路只有采购数据商，价格未公开 | 回复写明已查和未覆盖 |
| 大规模活模型评测、重复采样验收 | 多数论文和原则 11 的严格读法 | 业主反馈；评测不能变成发版条件 | 第 5.5 节 |
| 所有运行都用 10 万次 | FDA、E20 惯例 | 那是报告 I 类错误的惯例；引擎只有一个计算队列（10-25 审查，本次未复核），探索用途不值得 | 见决定 3 |

## 7. 只有你能决定的事

不答就按默认走。

| # | 决定 | 选项和代价 | 建议默认 |
|---|---|---|---|
| 1 | 工作台分支是否先合入 | 不合入：VCR 前端约 84 个文件会冲突。合入：等它先过验收，后端可并行 | **先合入**，后端和技能先开工 |
| 2 | SMD 大于 0.1 时从“不可估计”改为“受限并显示数值和最差变量” | 改：给出的数更多，受限的读法要讲清。不改：不一致于 9-29“不做整包否决”，且 0.1 只是惯例。注意 RCT-DUPLICATE 用它作可行性门槛，所以不是说它不重要 | **改为受限** |
| 3 | 零效应仿真的重复次数 | 全部 10 万：CPU 约 5 倍，排队变长。按用途：探索保持 2 万并显示误差；借用设计、指定分析及以上用 10 万。p=0.025 时半宽 0.0022 对 0.00097（自算） | **按用途** |
| 4 | 匹配评测的数据 | n2c2：公开基准、英文，要走其数据申请流程（本地是否已有未确认）。合作方中文病例：有差异化价值（10-25 调研没有找到“中文入排 + 中文真实病历 + 报准确率”的先例），但要两位医生独立标注，你来找合作方 | **先做 n2c2**；有合作方再做约 50–100 例中文。n2c2 申请如果拖太久，退到公开的 TrialGPT 数据（10-29 整理过 1,015 条，整理结果不在这台机器上），但那是合成病例，只能当回归检查 |
| 5 | 是否建随机加借用的混合设计（L） | 建：约一周以上，新增漂移和重叠假设。不建：`single_arm_external` 和 MAP 表（A11）先够用；新方法说样本量依赖“设计时拿不到的信息”，只见摘要 | **暂不建**，有真实需求再做 |
| 6 | “合成对照”改名“对照研究” | 改：减少和 Medidata 那种历史数据对照臂的混淆，要动文案和搜索别名。不改：继续解释 | **改**（模块名不变） |
| 7 | 是否跑一次 V3 原生对照 | 跑：约 12 段真实对话，一个下午，是回答“比原生好在哪”的唯一数据。不跑：简报第 5.3 节这一格继续空着。与原则 11“多次采样”不完全一致，此处按你的过度测试反馈只跑一次 | **Phase 1 后跑一次**，不作发版条件 |
| 8 | 模型库选哪 2–3 个病种（简报第 7 节 P2-10） | 没有数据和模型是最大缺口，但成本不小；选错就白做 | **Phase 2 完成后**按真实使用选 |

## 8. 来源和强度

### 8.1 怎么看这些证据

| 等级 | 包括 | 使用方式 |
|---|---|---|
| 随机试验 | RECTIFIER JAMA 2025（单中心，页面未写 AI 组产出） | 只说明吞吐，不外推 |

| 等级 | 包括 | 使用方式 |
|---|---|---|
| 监管和指南 | FDA 2019、2023（器械）、2023（协变量）、2023 外部对照**草案**、2025 AI **草案**、2026 贝叶斯**草案**；ICH M15、E20 **草案**；EMA 2024；CDE 2025 第 54 号、2026 第 6 号（全文）、第 27 号（沿用前次阅读） | 做流程依据，不当法规要求，合规本身不在范围内 |
| 同行评议 | TrialGPT、n2c2、Hernán、TARGET、RCT-DUPLICATE、Guyot、TSD 18、DELTA2、Morris、Charles、Azizi、El Emam、DT-GPT、Delphi-2M、StatQA、EmulatRx、TrialMind | 可引，单项研究结论不外推 |
| 预印本 | TrialGPT 2.0、PRISM、Wornow、UTSW、PowerGPT、**ClinAgent**、P-Bench、Li、Ask or Assume、LHAW、Fernandes（只读摘要）、KM-GPT | 只作方向 |
| 厂商 | Massive Bio、Inato、Unlearn、Nova、Veristat、Cytel、Certara、QuantHealth | 看架构，不信数字 |
| 只见摘要或二手 | Bartlett、JNCI 肿瘤（简报摘要）、Gartlehner（摘要页）、MediQ、SkillsBench、Schmidli | 标明后才用 |

我们自己的估算（已在文中标注）：p=0.025 下不同重复次数的半宽、HR 0.66→0.72 时把握度 90%→约 73%、139 个单位的样本量估算。这些不是发表数字。部分页面是经摘要工具读取的，调研记录里已标明，比如 Hernán、RCT-DUPLICATE 和 Guyot。

**没有验证的：** 没有运行任何东西。引擎数值、页面渲染、生产开关（`OPEN_SCIENCE_VCR_ENABLED` 代码默认关，`S/config.mjs:1061`）、回复检查是否开启（`S/config.mjs:1461`）、内核对链接的渲染、文献证据能否进入合并，都未确认。

## 8.2 2026-11-01 简报的勘误（简报已同步改正）

| 位置 | 原说法 | 应为 |
|---|---|---|
| 第 5.3 节、附录 | PowerGPT 对照 55.4%，大模型接统计引擎 | 对照是人用教科书、软件和搜索且不用 AI，**不是裸模型**；不能作为“引擎胜过单独模型”的证据（原文） |
| 第 3.4 节、附录 | “同行评议的 ClinAgent 研究”，模型生成分析规格总体正确率 72.1% | 这是**单作者预印本**在一个合成二期研究上的推导准确率；文中总体变量准确率 57.0%；**未确认它就是** Biology Methods and Protocols bpag032 那篇 |
| 第 7 节 P0-1 | 把对话研究纳入首页列表 | 方向对，但放宽现有查询会沿共用接口影响知识库的项目选择，复现 PR #17 那类问题（第 4.3 节） |
| 第 7 节 P0-2 | 回复附结果页链接 | 普通路径在内嵌页里不一定能点（第 4.3 节） |
| 第 7 节 P0-3 | 入口改成一个输入框 | 与“只有原生输入框”冲突，改为示例填草稿 |
| 第 2.4 节 | 路径只有站内通知 | 还有轻提示；而患者匹配连通知也没有 |
| 第 3.3 节 | “一次只问一件事”已写进规则 | 在 VCR 技能里没搜到这句；现有规则是“不要问用户确认…只有一种情况该问”。C2 补上 |

另外两处：工作台方案说“`vcrNext.mjs` 已不在代码里”，文件其实还在，只是没有服务端调用者，分支上也一样。代码核对时说“5/12”没找到，后来找到了出处（第 5.5 节），简报的数字成立。

### 8.3 调研记录之间的分歧（没有私自选边）

| 事项 | 分歧 | 这里的处理 |
|---|---|---|
| CDE 2026 第 6 号 | 设计部分的调研只读到征求意见稿，对照部分读了正式 PDF | 用正式稿；两者的“至少 10 万次”都是例子，不是硬门槛 |
| RECTIFIER 研究人员敏感性 | 90.1% 对 90.8% | 未解决，未引用 |
| Wong F1 76.1 等 | 10-25 的记录说是结构化 F1，这次读全文后更正为端到端匹配 F1 | 以全文为准，未在正文使用 |
| RCT-DUPLICATE 显著性一致率 | 10-25 的记录称勘误后 72%，PMC 页面仍是 75% | 正文只引相关系数 |
| THESEUS 评估集 | 预印本 15+5，Dryad 记录 30 | 未在正文引数字 |
| Gartlehner | 两个二手来源的次要数字不同 | 只引摘要页主数字，并标注 |
| EmulatRx 种子和缓存 | 同一全文的两段抽取说法相反 | 未作判断 |
| Gupta 比较数 | 同页 14 与 15 | 未引用数量 |
| Massive Bio 人审比例 | 15% 与前 25% | 引 15%，论文自己没有调和 |
| SkillsBench | 16.4 与 16.2 个百分点 | 正文不引数字 |

## 结语

这批论文改变的判断是：最有价值的不是加方法，而是**把已有的东西默认亮出来**。几乎每一类论文的共同要求（零效应情景、默认值回显、适用性记录、结果分级），在我们这里要么已算未显示，要么只差一行规则，而且都能在不加任何关卡的前提下完成。代价是不能再靠“有 34 个方法”来讲价值：用户拿到的应该是一句话能说清的东西，“这个结论成立的前提是这些假设，改一个看看”。第二个发现是，修流程本身也有风险：一处看起来很小的查询放宽，会沿着共用接口影响到知识库的项目选择。所以 Phase 0 虽然最小，也应该带着对这条边界的测试一起上。